



Introducción al pensamiento Bayesiano en modelos evolutivos

Hepática del día:
Frullania franciscana



Parsimonia

**Máxima
Verosimilitud**

Bayesian



Parsimonia

**Máxima
Verosimilitud**

Bayesian

Usa un
**criterio de
optimalidad**
para
seleccionar
un árbol

Parsimonia

Máxima Verosimilitud

Bayesian

Usa un
**criterio de
optimalidad**
para
seleccionar
un árbol

- Se **modela** el proceso de evolución de manera mecánica.
- Estimamos **parámetros** a partir de la **verosimilitud (likelihood)** de los datos.

Parsimonia

Usa un **criterio de optimalidad** para seleccionar un árbol

Máxima Verosimilitud

- Se **modela** el proceso de evolución de manera mecánica.
- Estimamos **parámetros** a partir de la **verosimilitud (likelihood)** de los datos.

Bayesian

- Estimamos **Probabilidades posteriores** utilizando el teorema de Bayes.
- Se usan **priors**.


El mundo a través de los ojos de un bayesiano...

Ser Bayesiano es natural....



El mundo a través de los ojos de un bayesiano:


1. Los parámetros son **variables aleatorias**.



El mundo a través de los ojos de un bayesiano:

1. Los parámetros son **variables aleatorias**.

- las variables aleatorias tienen distribuciones de probabilidad
- Podemos usar las **reglas de probabilidad** para estimar los parámetros.



El mundo a través de los ojos de un bayesiano:

1. Los parámetros son **variables aleatorias**.

- las variables aleatorias tienen distribuciones de probabilidad
- Podemos usar las **reglas de probabilidad** para estimar los parámetros.

2. Teorema de Bayes

Priors



Inferencia bayesiana

Teorema de Bayes:

Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

Inferencia bayesiana

Teorema de Bayes:

parámetro(s)

$$P(\theta | X) = \frac{P(X | \theta)P(\theta)}{P(X)}$$

Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(\overset{\text{datos}}{\boxed{X}} \mid \theta)P(\theta)}{P(X)}$$

Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

$$\textit{PosteriorProbability} = \frac{\textit{Likelihood} * \textit{Prior}}{\textit{MarginalLikelihood}}$$

Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$


$$\textit{PosteriorProbability} = \frac{\textit{Likelihood} * \textit{Prior}}{\textit{MarginalLikelihood}}$$

Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

$$\text{PosteriorProbability} = \frac{\text{Likelihood} * \text{Prior}}{\text{MarginalLikelihood}}$$




Inferencia bayesiana

Teorema de Bayes:

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$


$$\text{PosteriorProbability} = \frac{\text{Likelihood} * \text{Prior}}{\text{MarginalLikelihood}}$$



Inferencia bayesiana

$$P(\theta | X) = \frac{P(X | \theta)P(\theta)}{P(X)}$$

$$\text{PosteriorProbability} = \frac{\text{Likelihood} * \text{Prior}}{\text{MarginalLikelihood}}$$




Inferencia bayesiana

No solo nos interesa el pico de la distribución sino todos los valores.

$$P(\theta | X) = \frac{P(X | \theta)P(\theta)}{P(X)}$$

$$\text{PosteriorProbability} = \frac{\text{Likelihood} * \text{Prior}}{\text{MarginalLikelihood}}$$



Inferencia bayesiana

El denominador se llama la ***verosimilitud marginal de los datos...***

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

$$PosteriorProbability = \frac{Likelihood * Prior}{MarginalLikelihood}$$

Inferencia bayesiana

El denominador se llama la ***verosimilitud marginal de los datos***...

... que resulta ser

super difícil de calcular!

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

$$\text{PosteriorProbability} = \frac{\text{Likelihood} * \text{Prior}}{\text{MarginalLikelihood}}$$

$$P(X) = \int_{\theta} P(X \mid \theta)P(\theta)d\theta$$

$$P(X) = \int_{\theta_1} \int_{\theta_2} \int_{\theta_3} P(X \mid \theta_1, \theta_2, \theta_3)P(\theta_1)P(\theta_2)P(\theta_3)d\theta_1d\theta_2d\theta_3$$

Pero!

... podemos utilizar MCMCs
para aproximar la distribución a posteriori!

Cadenas de Markov Monte Carlo (MCMC)

Usamos *Cadenas de Markov Monte Carlo* (MCMC) para aproximar distribuciones posteriores de los modelos Bayesianos.

Cadenas de Markov Monte Carlo (MCMC)

Usamos *Cadenas de Markov Monte Carlo* (MCMC) para aproximar distribuciones posteriores de los modelos Bayesianos.

MCMC es un **algoritmo** que muestrea la distribución a posteriori sin necesidad de calcular la verosimilitud marginal.

-Esto es posible ya que compara el numerador del teorema de Bayes entre dos muestras.

Cadenas de Markov Monte Carlo (MCMC)

Let's go through an example
with two parameters:


$$\theta_1 \text{ and } \theta_2$$

Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by **randomly** choosing a **starting value** for every parameter (θ_1 and θ_2)


Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by **randomly** choosing a **starting value** for every parameter (θ_1 and θ_2)




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. **Choose one parameter** at random, e.g., θ_1




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. **Propose** a **new value** for the parameter, θ_1



Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. **Propose** a **new value** for the parameter, θ_1




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the **acceptance probability**:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

θ_2



θ_1


Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. **Accept or reject** the proposal

θ_2




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal θ_2
7. Go back to step 2 (**repeat many many times**).




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).




Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).



Cadenas de Markov Monte Carlo (MCMC)

1. Initialize the chain by randomly choosing a starting value for every parameter (θ_1 and θ_2)
2. Choose one parameter at random, e.g., θ_1
3. Propose a new value for the parameter, $\hat{\theta}_1$
4. Compute the *acceptance probability*:

$$R = \min \left[1, \frac{P(X | \hat{\theta}_1)}{P(X | \theta_1)} \times \frac{P(\hat{\theta}_1)}{P(\theta_1)} \right]$$

5. Draw $u \sim U(0,1)$. If $u < R$, accept the proposal; otherwise, reject it.
6. Accept or reject the proposal
7. Go back to step 2 (**repeat many many times**).





Cadenas de Markov Monte Carlo (MCMC)

Al final de la MCMC, tenemos una **muestra** de la distribución **posterior** de todos los parámetros.

Cadenas de Markov Monte Carlo (MCMC)

Al final de la MCMC, tenemos una **muestra** de la distribución **posterior** de todos los parámetros.


El histograma de cada parámetro es **proporcional** a la **distribución de la probabilidad del parámetro**.



Cadenas de Markov Monte Carlo (MCMC)

Al final de la MCMC, tenemos una **muestra de la distribución posterior** de todos los parámetros.

El histograma de cada parámetro es **proporcional a la distribución de la probabilidad del parámetro**.



Ventajas prácticas de la inferencia bayesiana:

- Incorpora **medidas de incertidumbre** que son directas de obtener y fáciles de interpretar
 - Probabilidades posteriores, intervalos de credibilidad, etc.
- Los modelos jerárquicos son fáciles de implementar mediante el teorema de Bayes.
 - Se pueden incorporar **distintas fuentes de información**.
 - Es relativamente sencillo **implementar modelos de inferencia conjunta**.


Sin embargo, hay un **trade-off**:

- Al igual que en ML, los resultados pueden ser **sensibles** al modelo que se asume.
- Especificar **priors**, puede ser complicado y tener efectos no anticipados.
- Se usan MCMCs, y estas pueden **consumir mucho tiempo y en ocasiones fallar**.

Podemos realizar nuestra inferencia bayesiana con varios programas:



RevBayes



BEAST

Bayesian Evolutionary Analysis Sampling Trees



Mr. Bayes

¿Por qué RevBayes?



```
19
20
21 # CONSTANT RATE DIVERSIFICATION MODEL
22
23 # empirical prior on the diversification rate
24 diversification_prior_mean <- ln(total_taxa) / origin_time
25 diversification_prior_sd <- H
26
27 # the diversification rate
28 diversification ~ dnLognormal( ln(diversification_prior_mean) - diversification_prior_sd * diversification
29 moves.append( mvScale(diversification, weight = 1.0) )
30
31 # the relative extinction rate
32 relext ~ dnUniform(0, 1)
33 moves.append( mvSlide(relext, weight = 1.0) )
34
35 # transform to real parameters
36 lambda := abs(diversification / (1 - relext))
37 mu := abs(lambda * relext)
38
39
40 # CONSTANT-RATE FOSSILIZATION MODEL
41
42 # empirical prior on the fossilization rate
43 fossilization_prior_mean <- num_fossils * diversification_prior_mean / (exp(diversification_prior_mean * o
44 fossilization_prior_sd <- 2 * H
45
46 # the fossilization rate
47 psi ~ dnLognormal( ln(fossilization_prior_mean) - fossilization_prior_sd * fossilization_prior_sd * 0.5, f
48 # add moves
49 moves.append( mvScale(psi, weight = 1.0) )
50
51
52 # make the FBD tree
53
54 timetree ~ dnFBDP(
55 | | originAge = origin_time,
```


- Lenguaje de programación enfocado en filogenética.
 - Basado en R
- Dinámico; permite construir modelos complejos y especificar tus propios priors
- Te obliga a pensar en tu modelo y en tus priors.

MCMC en acción:

Pero ¿cómo sabemos si nuestro MCMC está funcionando bien?

MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?




MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?

MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?


Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?



Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?



Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?


Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?


Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?

Convergencia: la cadena ha llegado o no a la distribución **posterior**



MCMC en acción:


Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?

Mezcla (Mixing): la cadena esta muestreando eficientemente el espacio del parámetro.

MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?


Mezcla (Mixing): la cadena esta muestreando eficientemente el espacio del parámetro.



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?



Mezcla (Mixing): la cadena esta muestreando eficientemente el espacio del parámetro.



MCMC en acción:



Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?

Mezcla (Mixing): la cadena esta muestreando eficientemente el espacio del parámetro.



MCMC en acción:

Como usuarios, ¿cómo sabemos si nuestro MCMC está funcionando bien?



Take aways/para llevar

- La inferencia bayesiana trata a los parámetros de interés como **variables aleatorias**.
 - Cada variable aleatoria (parámetro) puede ser estimada usando su **distribución** de probabilidad.
- La inferencia bayesiana se basa en el teorema de Bayes: Prior, likelihood, marginal likelihood.

$$P(\theta \mid X) = \frac{P(X \mid \theta)P(\theta)}{P(X)}$$

- Las MCMC es un algoritmo que permite aproximar la probabilidad posterior sin necesidad de calcular verosilimilitudes marginales.



¿Preguntas?